



计算机工程

Computer Engineering

ISSN 1000-3428, CN 31-1289/TP

## 《计算机工程》网络首发论文

题目： 基于领域自适应的卫星工程参数异常检测  
作者： 王爱玲，马文臻，邹自明，钟佳  
DOI： 10.19678/j.issn.1000-3428.0064512  
网络首发日期： 2022-08-09  
引用格式： 王爱玲，马文臻，邹自明，钟佳. 基于领域自适应的卫星工程参数异常检测[J/OL]. 计算机工程. <https://doi.org/10.19678/j.issn.1000-3428.0064512>



**网络首发：**在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

**出版确认：**纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。



## 基于领域自适应的卫星工程参数异常检测

王爱玲<sup>1,2</sup>, 马文臻<sup>1</sup>, 邹自明<sup>1</sup>, 钟佳<sup>1,2</sup>

(1.中国科学院国家空间科学中心, 空间科学卫星运控部, 北京 100190; 2.中国科学院大学, 计算机科学与技术学院, 北京 100049)

**摘 要:** 卫星工程参数异常检测是判断卫星与载荷健康状态的重要手段。传统的异常检测方法往往针对具体的卫星或载荷而设计, 遇到新卫星任务、新载荷时迁移检测效果并不理想, 需要重新建模和训练, 然而新运行的卫星设备尚未产生足够的历史数据来支撑建模任务。针对上述问题, 融合深度学习和迁移学习思想, 提出了一种基于领域自适应的卫星工程参数异常检测方法。利用深度残差收缩网络的结构框架, 训练过程中同时将无标签的目标域卫星工程参数数据加入到网络的训练过程中, 有效获取了数据的特征表示, 为后续的相似性度量奠定基础; 对所提取到的数据特征使用距离度量, 衡量所提取到的源域特征与目标域特征之间的差异性, 使得二者在特定特征空间上的分布相似, 从而增强了网络利用已有标签数据对无标签数据分类的能力。在基于空间科学先导专项系列卫星工程参数构建的数据集上验证, 结果表明, 该方法的准确率达到 98.03%, 与梯度提升决策树、支持向量机、深度残差收缩网络三种方法相比, 该方法的迁移检测平均准确率分别高出 20.95%、22.51%、15.02 个百分点, 能够有效地达到对新卫星、新载荷开展快速准确异常检测的目的。

**关键词:** 卫星工程参数; 异常检测; 深度学习; 迁移学习; 领域自适应



开放科学(资源服务)标志码(OSID):

## Anomaly Detection of Satellite Engineering Parameters Based on Domain Adaptation

Wang Ailing<sup>1,2</sup>, Ma Wenzhen<sup>1</sup>, Zou Ziming<sup>1</sup>, Zhong Jia<sup>1,2</sup>

(1. Space Science Mission Operation Center, National Space Science Center, Chinese Academy of Sciences, Beijing 100190, China;

2. School of Computer Science and Technology, University of Chinese Academy of Sciences, Beijing 100049, China)

**【Abstract】** Anomaly detection of satellite engineering data refers to applying some methods to analyze satellite engineering data in order to judge the health status on satellites and payloads. However, conventional anomaly detection methods are trained and designed in a single satellite data, achieving a poor detection effect on anomaly detection task in a new satellite. Besides, there is not enough data from a new satellite in-orbit for training. To solve this problem, this paper proposes an anomaly detection method for satellite engineering data based on domain adaptation. Applying residual shrinkage network architecture can extract the features of detected data via adding unlabeled detected data into training process. In addition, to estimate dissimilarity between source and target domain features, this method uses similarity measure. Meanwhile, it can enhance classification ability. Based on engineering datasets from satellites in Space Science Pioneer Project, compared with Gradient Boosting Decision Tree, Support Vector Machine, and Deep Residual Shrinkage Network, detecting accuracy has been improved by 20.95%, 22.51% and 15.02%, respectively. Thus, this algorithm can reach the goal of precise and fast anomaly detection on a new satellite or a new payload.

**【Key words】** satellite engineering parameters; anomaly detection; deep learning; transfer learning; domain adaptation

DOI:10.19678/j.issn.1000-3428.0064512

### 0 概述

根据互联网公开资料对全球 2003 年至 2020 年

**基金项目:** 中国科学院“十四五”网络安全和信息化专项(WX145XQ07-06), 中国科学院网信专项(CAS-WX2021PY-0101)

**作者简介:** 王爱玲(1997—), 女, 硕士研究生, 主研方向: 日地空间大数据处理与应用技术; 马文臻, 副研究员; 邹自明, 研究员; 钟佳, 副研究员。E-mail: mawenzhen@nssc.ac.cn

的在轨运行卫星故障情况统计分析,发现有 91 颗在轨卫星发生故障<sup>[1]</sup>,这些故障分布在卫星的各个分系统上;随着航天技术的不断更新,卫星上搭载的载荷数量和种类随之增多,卫星系统的构成也更加复杂<sup>[2]</sup>,因此,为了有效监测卫星在轨运行的健康状况,需要对卫星工程参数进行异常检测。

卫星工程参数与星上载荷设备的性能状态息息相关,反映了设备的功能以及工作性能的变化,是地面运控人员了解卫星平台及载荷设备运行状态的直接依据,也是唯一依据。卫星工程参数异常检测,不仅能够判断卫星与载荷的健康状态、评估星上元器件寿命,同时能够为科研人员提供依据,方便科研人员及时有效进行故障处置,从而保障卫星在轨任务的顺利运行。

在卫星工程参数异常检测研究领域,目前主流的方法可以归纳为两大类:统计学方法和机器学习智能方法。

基于统计学的卫星工程参数异常检测方法最常用的有阈值门限法、协方差分析和数据相关性分析等。

阈值门限法通过设定与载荷设计一致的阈值来实现对卫星工程参数异常的检测,操作简单,然而很多类型的异常并不会引起阈值范围外的变化;且当卫星载荷发生性能变化时,需要再次设定新的阈值来适应载荷的变化;此外卫星工程参数维度高,对卫星的每个参数都进行设定,极大地增大了工作量;为解决这一问题,Kawahara 等人<sup>[3][4]</sup>从卫星运行产生的历史数据中学习得到阈值范围,但是,随着卫星寿命的增长,星上元器件的老化磨损将导致参数的阈值范围发生变化,而一段时间内学习得到的阈值并不会更新,因而无法达到理想的异常检测效果。

协方差分析法是针对周期内变化趋势相同的数据来进行异常检测的,可以有效地检测出周期性数据的异常,但是对于周期时间长、数据量大的数据,耗时较长,且对于局部异常数据不敏感<sup>[5]</sup>。

相关性分析法是针对多个参数之间的相关关系建立的,对卫星中存在相互影响的遥测数据有很好的检测效果,但是其计算量较大,对于一些同时发生变化的参数,并不能起到很理想的检测效果<sup>[6]</sup>。

基于机器学习的卫星工程参数异常检测方法主要有基于支持向量机的方法、基于神经网络的方法和基于聚类的方法等。

基于支持向量机(Support Vector Machine, SVM)<sup>[7][8]</sup>的方法在卫星工程参数异常检测上取得了良好的准确性,但是由于通常结合主成分分析方法(Principal Component Analysis, PCA)对数据进行预处理降维,在处理非线性问题方面有局限性,可能导致异常检测效果不明显;除此之外,由于 SVM 是一种监督学习方法,在卫星实际运行过程中,完成对海量数据的逐一标注工作相对而言比较困难。

基于神经网络的方法<sup>[9][10]</sup>则有效解决了对输入数据本身特点要求比较高这一问题,高维数据得以有效地被检测,以长短期记忆网络(Long Short-Term Memory, LSTM)<sup>[11]</sup>为例,能更好地记忆长时间内的数据相关性,适合处理时序数据,但是只能使用卫星某一分系统的卫星工程参数来训练建模检测该分系统下的数据异常情况,在不同卫星相似子系统上的异常检测效果并不理想。

相较于以上两种方法,聚类方法能够实现无监督学习<sup>[12]</sup>,不需要耗费人力再进行数据标注;但是聚类方法对噪声信息比较敏感,当数据在数据传输过程中混入噪声数据时,检测效果较差。

综上所述,一方面,使用传统的异常检测方法需要获取工程参数明确的标签信息,这一过程耗时长,实现起来比较困难,以量子科学实验卫星为例,自 2016 年 8 月发射时起,至今获取的工程参数规模已达到 TB 级别;另一方面,不同卫星之间数据分布之间存在一定差异,传统异常检测方法需要足够数量的卫星工程参数作为数据支撑,而新的卫星、搭载的新载荷在发射之初,并没有积累足够的工程参数数据,使用传统的异常检测方法无法建立有效的检测模型,因而只能依赖传统的阈值法和统计方法,工作量大且方法扩展性较差,准确率和效率较低,往往在单一卫星单一分系统下能发挥出优异的检测性能,而在新卫星、新载荷上的异常检测任务中则表现不佳。为了解决以上问题,需要建立一种高效、准确的方法对新卫星的工程参数进行异常检测。而领域自适应是利用数据、任务或者模型之间的相似性,将在一个领域学习到的模型和知

识应用到另一个新的领域,从而实现从一个领域到另一个领域的迁移学习效果。目前领域自适应在金融欺诈检测<sup>[13]</sup>、交通流量预测<sup>[14]</sup>、恶意软件检测<sup>[15]</sup>、银行安全系统<sup>[16]</sup>、通信用户量预测<sup>[17]</sup>、轴承故障诊断<sup>[18][19]</sup>领域,均有相关成功应用的案例,体现出领域自适应方法强大的应用潜力,在卫星工程参数异常检测领域尚未见到文献发表类似研究结果。

本文通过分析了现有的异常检测方法在样本标注困难、通用性较差从而导致在新卫星、新载荷上迁移检测效果不理想的问题,提出了一种基于领域自适应的异常检测方法。实验结果表明,相较于传统的机器学习方法,该方法能够有效地提取卫星工程参数特征,提升检测准确率,可以在不同卫星相似分系统的工程参数之间进行智能迁移扩展,支持利用已有卫星型号的经验针对新卫星型号快速开展高效的异常检测工作,大大节省建立新模型的工作量,提高卫星异常检测效率。

## 1 卫星工程参数描述

不同卫星的设计特点是不一致的,但是卫星之间具有相同或者相似的分系统,例如供电分系统、星务分系统、测控与姿控分系统等,而这些不同卫星对应分系统下所包含的物理参数也类似,都表征了卫星相似的运行特性,因此利用已有卫星分系统的工程参数对新卫星相似分系统进行异常检测具有可行性。

本文所使用的卫星工程参数来源于空间科学先导专项系列卫星中的两颗卫星:量子科学实验卫星、“太极一号”微重力技术实验卫星,基于对两颗卫星的设计特点和长期管控经验,根据卫星工程参数表现特征,选取了卫星在轨运行过程中常见的五种异常,包括时间码异常、供电异常、星务异常、数传通信异常、测控与姿控异常。

对于每一类数据中所涉及的参数,大多数有相对应的阈值范围,超出阈值范围或在阈值范围内发生剧烈波动的数据视为异常数据。对于某些异常计数类的参数,阈值内如果发生加 1,即表明计数出现异常,因此则将该数据标记为异常数据,不变化或者一定时间后自动清零均为正常。有的参数则为固定取值,一旦出现其他取值即为异常,例如,对

于部分运行模式控制的参数,模式状态为“最小模式”时为异常。

图 1-图 4 展示了量子科学实验卫星中四种阈值类参数随时间的变化趋势,分别为“纠缠 45V 电源”、“纠缠 12V 电源”、“纠缠-12V 电源”、“试验板电源温度”,可以看出,每种参数的变化与开关机状态之间存在相关性,且不同参数之间也存在一定相关性。

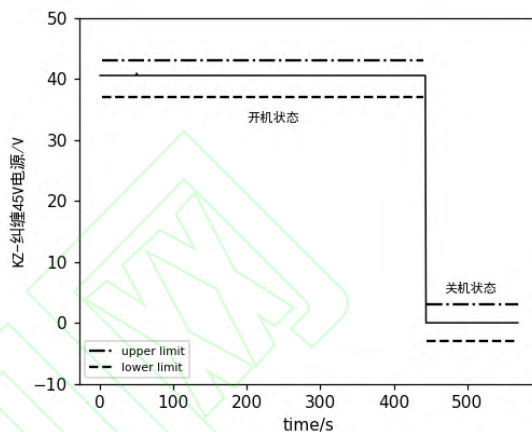


图 1 纠缠 45V 电源变化趋势图

Fig.1 Trend of power supply with 45V




图 2 纠缠 12V 电源变化趋势图

Fig.2 Trend of power supply with 12V






图 3 纠缠-12V 电源变化趋势图

Fig.3 Trend of power supply with -12V




图 4 试验板电源温度变化趋势图

Fig.4 Trend of power temperature on experiment board

## 2 迁移学习与领域自适应概述

为了更好地理解领域自适应方法在卫星工程参数异常检测领域的应用场景,本节对所设计到的迁移学习背景进行简要介绍,其次阐述领域自适应的技术方法,为后续模型的构建提供理论支撑。

### 2.1 迁移学习

本文中卫星工程参数异常检测是二分类任务,即对于一系列卫星工程参数特征  $X$  及其对应的分类类别标签  $Y$ ,工程参数特征  $X$  构成了一个领域,称之为  $D$ ,通过构建参数特征  $X$  与标签  $Y$  之间隐藏的映射关系,即目标函数  $f: X \rightarrow Y$ ,完成对数据的分类任务。一般情况下,针对单一领域下的分类任务,整个过程分为两个步骤:首先,将参数特征  $X$  经过特征表示函数  $h(\bullet)$  映射到隐含特征空间  $Z$  上,

即  $h: X \rightarrow Z$ ;学习器通过学习,获得最优的特征表示  $h(\bullet)$  和一个最优的目标函数  $g(\bullet)$  来近似真实目标函数  $f$ 。针对两个领域下的应用场景,迁移学习是利用数据、任务或者模型之间的相似性,将在旧领域学习得到的模型和知识应用于新的领域<sup>[20]</sup>,其中旧领域称为源域  $D_S$ ,新领域称为目标域  $D_T$ 。因此,迁移学习的目标是通过提取源域  $D_S$  的特征,来提升特征表示函数  $h(\bullet)$  对目标域  $D_T$  数据的特征表示与特征提取能力。

根据特征空间的特性,可以将迁移学习划分为两大类:同构迁移学习和异构迁移学习。同构迁移学习的源域和目标域参数特征相似但并不完全相同,但是样本的类别空间一致;而异构迁移学习的源域和目标域参数特征与样本空间完全不一致。

除此之外,和机器学习分类方法类似,根据目标域数据有无类别标签,可将迁移学习分为三类:有监督迁移学习,即  $D_T = \{(x_1, x_2, \dots, x_N), (y_1, y_2, \dots, y_M)\}$ , 其中  $M = N$ ; 无监督迁移学习,即  $D_T = \{(x_1, x_2, \dots, x_N)\}$ ; 半监督迁移学习,即  $D_T = \{(x_1, x_2, \dots, x_N), (y_1, y_2, \dots, y_M)\}$ , 其中  $M < N$ 。 $M$  和  $N$  分别为带标签的样本数量和数据样本总数。

本文所使用的领域自适应方法属于无监督同构迁移学习范畴,2.2 节将对领域自适应的相关技术进行详细介绍。

### 2.2 领域自适应

如 2.1 节所述,领域自适应属于无监督迁移学习的一个领域,因此表示为源域  $D_S = \{X_S, Y_S\}$ ,目标域  $D_T = \{X_T\}$ 。领域自适应的目标有两个,其一是通过学习获取一个通用的特征表示函数  $h(\bullet)$ ,将  $D_S$  和  $D_T$  分别映射到各自对应的特征空间  $Z_S$  和  $Z_T$  上,使之能够同时表征  $D_S$  和  $D_T$ ,为了使  $D_S$  和  $D_T$  在对应的特征空间  $Z_S$  和  $Z_T$  上更相似,使用距离度量函数  $d(Z_S, Z_T)$  来衡量二者之间的相似性,通过降低  $d(Z_S, Z_T)$  的大小,获取最优的  $h(\bullet)$ ;其二是利用  $D_S$  的类别标签  $Y_S$  训练得到一个最优的分类函数  $g(\bullet)$ ,使得  $g(\bullet)$  在  $D_S$  和  $D_T$  上对数据的分类效果同时达到最优。图 5 展示了领域自适应的基本思想,

其中“+”、“-”分别表示源域数据映射后的正例特征和负例特征，“•”、“▲”分别表示源域数据映射后的正例特征和负例特征。如(a)所示，在领域自适应之前，由于源域和目标域的数据分布不一致，分类函数 $g(\cdot)$ 可以有效地将源域数据的正例和负例特征区分开，而在对目标域数据的分类上则存在错分情

况；经过领域自适应之后，如源域和目标域数据被映射到两个相似的特征表示下，在这个特征空间下，源域特征与目标域特征分布近似，再重新学习得到一个新的分类函数 $g'(\cdot)$ ，可以直观看出， $g'(\cdot)$ 不仅可以将源域数据的正负例样本分开，而且对目标域数据的正负例样本也没有错分情况。

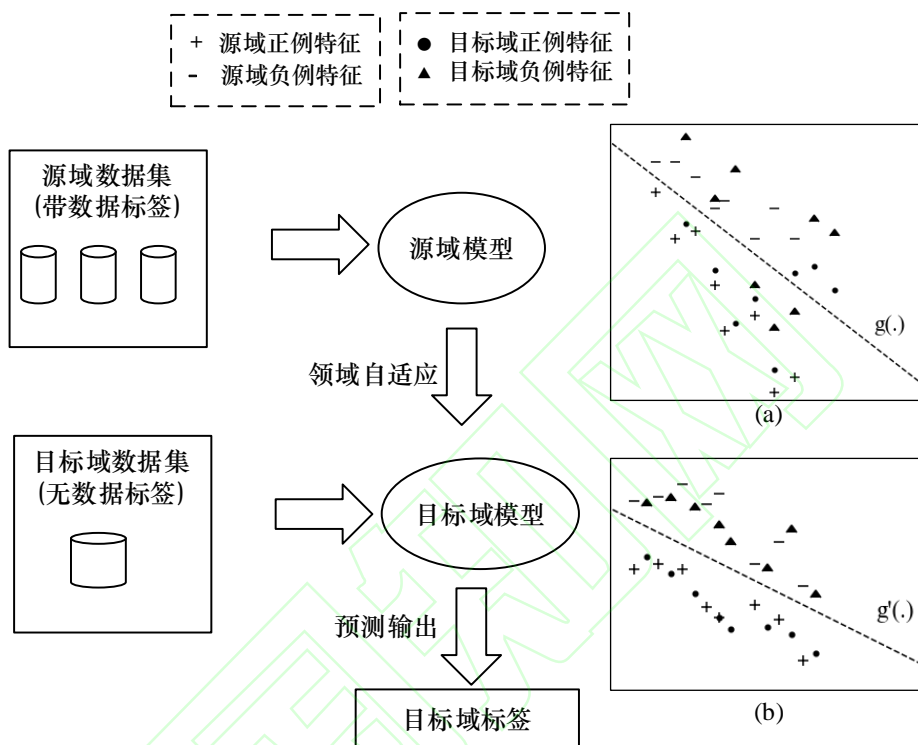


图5 领域自适应基本思想

Fig.5 Basic idea of domain adaptation

### 3 基于领域自适应的卫星工程参数异常检测模型

#### 3.1 数据选择

本文选用量子科学实验卫星（简称“量子卫星”）2019年在轨运行工程参数以及“太极一号”微重力技术实验卫星（简称“太极一号”卫星）2020年在轨运行得到的工程参数作为实验对象。数据由国家科技资源共享服务平台-国家空间科学数据中心 (<https://www.nssdc.ac.cn>) 提供。根据量子卫星、“太极一号”卫星自身的设计特点及其工程参数属性组织结构特征，本文选取了量子卫星的3大类工程参数，将其合并组织为3类文件作为实验对象，分别为供电分系统工程参数A1、测控/姿控分系统工程参数A2和数传通信分系统工程参数A3；“太极一号”则分别对应选取供电分系统工程参数B1、测控

与姿控分系统工程参数B2和数传通信分系统工程参数B3。

由于卫星实际在轨运行过程中发生异常的频次较低，几乎没有异常数据，因此为了保证数据集的完备性，在原始工程参数数据中手动添加异常，根据第1节对异常类型的描述构建模拟数据集。针对每条工程参数数据，只要有一个参数表现为异常，则将其标注为异常。每类样本中异常数据与正常数据的占比大约为1:4。表1、表2分别展示了量子卫星和“太极一号”卫星模拟工程参数数据的基本情况。其中，APID（Application Identity）为应用过程标识符，在卫星数据采集和传输过程中用于区分不同数据的源设备；数据规模表示整个模拟工程参数数据集中所有数据的总条数。

表 1 量子卫星模拟工程参数数据描述

Table 1 Data description of Micius Quantum Experiment

Science Satellite		
样本类型	APID	数据规模/条
供电分系统工程参数 A1	0x0087	5.7e6
测控/姿控分系统工程参数 A2	0x004D-0001	6.3e7
数传通信分系统工程参数 A3	0x004D-0052	5.5e6

表 2 “太极一号”卫星模拟工程参数数据描述

Table 2 Data description of Taiji-1 Satellite

样本类型	APID	数据规模/条
供电分系统工程参数 B1	0x0801	5.2e6
测控与姿控分系统工程参数 B2	0x0811	5.5e6
数传通信分系统工程参数 B3	0x0880	7.8e6

### 3.2 模型结构

基于 2.2 节对领域自适应的阐述，基于领域自适应的卫星工程参数异常检测框架如图 6 所示。

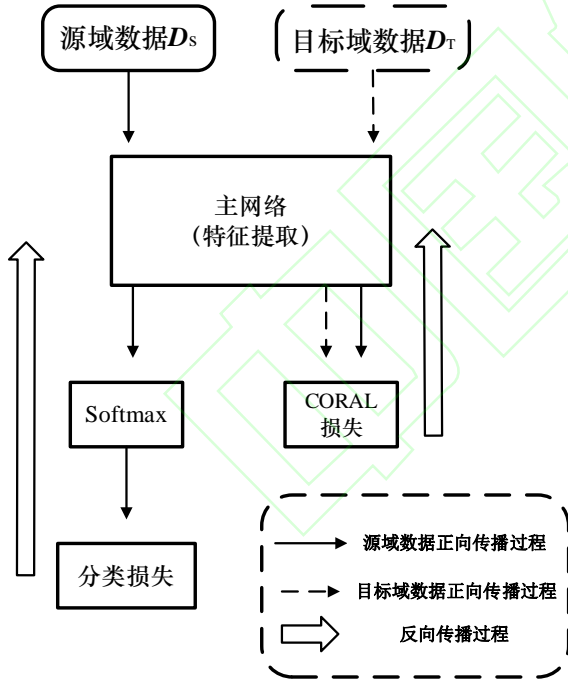


图 6 基于领域自适应的异常检测框架

Fig.6 Anomaly detection structure based on domain adaptation

在训练阶段，将具有完整类别信息的源域数据  $D_S$  和无标签的目标域数据  $D_T$  同时输入到模型主网络进行训练，网络经过学习得到的源域特征，既用

于计算分类过程产生的损失；又和网络输出的目标域特征一起，计算相关对齐（Correlation Alignment, CORAL）损失<sup>[21]</sup>，以此来评估网络提取到的源域和目标域的卫星工程参数特征在子空间上的相似性。

卫星工程参数可以看作是具有时序特征的多维数据参数的集合，而卷积神经网络（Convolution Neural Network, CNN）可以深入挖掘高维数据内部潜在的数据特征，因此利用该网络对卫星工程参数进行异常检测。CNN 最初由 Lecun 等人<sup>[22]</sup>提出，之后在此基础上得以改进，出现 DenseNet、AlexNet、ResNet 等一系列性能优异的卷积神经网络模型，而深度残差收缩网络（Deep Residual Shrinkage Network, DRSN）是 Zhao 等人<sup>[23]</sup>基于 ResNet 的网络特点提出的一种新的网络结构，可以有效地解决由数据噪声带来的特征提取效果不佳的问题，同时避免不必要特征对模型的干扰。

本文借鉴 DRSN 的基础网络结构残差收缩网络单元（Residual Shrinkage Network Unit, RSNU），所构建的卫星工程参数异常检测网络模型如图 7 所示。

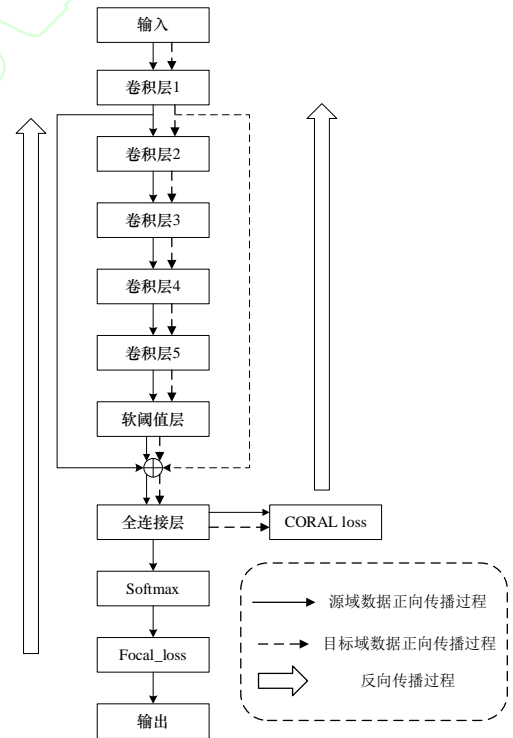


图 7 基于 DRSN\_CORAL 的异常检测模型

Fig.7 Anomaly detection model based on DRSN\_CORAL  
网络模型的结构和超参数设置如表 3 所示。

表 3 基于 DRSN 的网络超参数设置

Table 3 Parameters setting based on DRSN

网络层	相关超参数设置
输入	batch_size=64
卷积层 1	kernel_size:8*4, stride_step=2, 激活函数: LeakyReLU
卷积层 2	kernel_size:16*3, stride_step=1, 激活函数: LeakyReLU
卷积层 3	kernel_size:32*3, stride_step=1, 激活函数: LeakyReLU
卷积层 4	kernel_size:64*3, stride_step=1, 激活函数: LeakyReLU
卷积层 5	kernel_size:32*3, stride_step=1, 激活函数: LeakyReLU, pooling:GAP
全连接层	结点数: 64, 激活函数: LeakyReLU

卷积层 1 有 8 个通道, 卷积核大小为 4, 滑动步长为 2, 卷积层 2 含有 16 个通道, 卷积核大小为 3, 滑动步长为 1, 卷积层 3-5 的参数与卷积层 2 类似, 通道数分别为 32,64,32。每个卷积层的激活函数使用 LeakyReLU, 防止在训练过程中出现“神经元坏死”现象而导致网络训练终止的问题。卷积层 5 中的池化层选用全局平均池化 (Global Average Pooling, GAP)。

如图 6、图 7 所示, 网络训练的最终目的是降低分类损失和 CORAL 损失, 从而降低对源域的分类误差以及源域与目标域工程参数之间的差异性。反向传播过程中参数的更新原则为随机梯度下降 (Stochastic Gradient Descent, SGD)。

### 3.3 模型训练过程

本文中, 由于输入的卫星工程参数数据是一维的, 因此各个卷积层的卷积操作为一维卷积, 假设第  $i$  个卷积层源域和目标域特征的输出为  $\mathbf{x}_j^i$ , 即  $\mathbf{x}_j^i = \{\mathbf{x}_{j,S}^i, \mathbf{x}_{j,T}^i\}$ , 其中  $j=1,2,\dots,N$ ,  $N$  为一个 batch 中的样本总数, 第  $i$  个卷积层的系数为  $\mathbf{w}^i$ , 偏置项为  $\mathbf{b}^i$ 。所以第  $i$  个卷积层的卷积输出可以表示为如式(1)的形式。

$$\mathbf{x}_{j,\text{conv}}^i = \mathbf{w}^i * \mathbf{x}_j^{i-1} + \mathbf{b}^i \quad (1)$$

其中,  $*$  表示卷积操作, 卷积操作的输出  $\mathbf{x}_{j,\text{conv}}^i$  输入激活函数后, 作为一个卷积层的最终输出, 表达式如式(2)所示。

$$\mathbf{x}_{j,\text{act}}^i = \sigma(\mathbf{x}_{j,\text{conv}}^i) = \sigma(\mathbf{w}^i * \mathbf{x}_j^{i-1} + \mathbf{b}^i) \quad (2)$$

其中,  $\sigma(\bullet)$  为 LeakyReLU 函数。

所以, 网络前向传播时, 前 5 个卷积层的输出如式(3)-(7)所示。

$$\mathbf{x}_j^1 = \sigma(\mathbf{w}^1 * \mathbf{x}_j + \mathbf{b}^1) \quad (3)$$

$$\mathbf{x}_j^2 = \sigma(\mathbf{w}^2 * \mathbf{x}_j^1 + \mathbf{b}^2) \quad (4)$$

$$\mathbf{x}_j^3 = \sigma(\mathbf{w}^3 * \mathbf{x}_j^2 + \mathbf{b}^3) \quad (5)$$

$$\mathbf{x}_j^4 = \sigma(\mathbf{w}^4 * \mathbf{x}_j^3 + \mathbf{b}^4) \quad (6)$$

$$\mathbf{x}_j^5 = \text{GAP}(\sigma(\mathbf{w}^5 * \mathbf{x}_j^4 + \mathbf{b}^5)) \quad (7)$$

GAP( $\bullet$ ) 为全局最大平均池化函数, 对提取的特征值取平均, 可以有效减少训练参数数量并可以避免过拟合。

软阈值层的网络结构如图 8 所示。

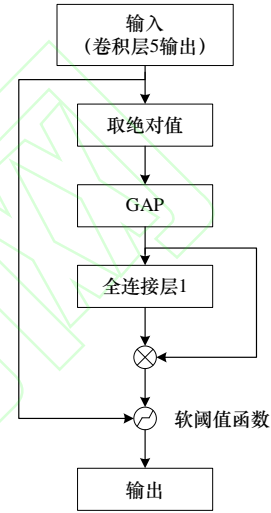


图 8 软阈值层网络结构

Fig.8 Structure of soft threshold layer

从图 7 可以看出, 软阈值层的输入为卷积层 5 的输出, 即  $\mathbf{x}_j^5$ , 经过取绝对值、GAP 操作后, 得到的输出如式(8)所示。

$$\mathbf{x}_{j,\text{soft\_GAP}}^5 = \text{GAP}(\text{abs}(\mathbf{x}_j^5)) \quad (8)$$

全连接层 1 的节点数为 32, 假设全连接层 1 的权重向量为  $\mathbf{k}_1$ , 偏置为  $\mathbf{b}_{\text{FC1}}$ , 所以, 全连接层 1 的输出可以表示成式(9)的形式。

$$\mathbf{x}_{j,\text{soft\_FC1}} = \mathbf{k}_1 \mathbf{x}_{j,\text{soft\_GAP}}^5 + \mathbf{b}_{\text{FC1}} \quad (9)$$

软阈值函数的表达式如式(10)所示, 其中  $\tau > 0$ ,  $x, x_{\text{soft}}$  分别为经过软阈值前后的特征值。

$$x_{\text{soft}} = \begin{cases} x - \tau, & x > \tau \\ 0, & -\tau \leq x \leq \tau \\ x + \tau, & x < -\tau \end{cases} \quad (10)$$

所以, 软阈值层最终的输出结果  $\mathbf{x}_{j,\text{soft}}$  为如式(11)所表示的形式。



$$\mathbf{x}_{j,\text{soft}} = \max([\text{abs}(\mathbf{x}_j^5) - (\mathbf{x}_{j,\text{soft\_FC1}} \cdot \mathbf{x}_{j,\text{soft\_GAP}})], 0) \cdot (\text{sign}(\mathbf{x}_j^5)) \quad (11)$$

软阈值层的输出与卷积层 1 相加, 作为全连接层的输入, 这样可以避免网络更新时梯度消失情况, 假设该全连接层的权重向量与偏置分别为  $\mathbf{k}, \mathbf{b}_{\text{FC}}$ , 则全连接层的输出可以表示为式(12)。

$$\mathbf{z}_j = \sigma(\mathbf{k}(\mathbf{x}_j^1 + \mathbf{x}_{j,\text{soft}}) + \mathbf{b}_{\text{FC}}) \quad (12)$$

在经过以上式(1)-(12)的处理后, 得到特征表示函数  $h(\cdot)$ , 即  $\mathbf{z}_j = h(\mathbf{x}_j)$ 。

由于只有源域卫星工程参数数据具有完整的类别标签, 因此, softmax 函数只作用与源域工程参数特征, softmax 输出结果如式(13)所示。

$$p = \frac{e^{z_{j,S}}}{\sum_{i=1}^C e^{z_{j,i,S}}} \quad (13)$$

其中,  $C$  为类别标签的数量, 本文中  $C = 2$ 。因此, 可以获得分类函数  $g(\cdot)$  的表达式, 如式(14)所示。

$$p = g(z_{j,S}) \quad (14)$$

分类损失函数用于计算网络输出值与真实值之间的差异性, 在传统的分类任务中, 一般采用交叉熵损失, 如式(15)。

$$\text{Loss}_{\text{cross\_entropy}} = -y \log(p) - (1-y) \log(1-p) \quad (15)$$

其中,  $y$  为数据真实类别标签。

卫星在运行过程中异常发生频次较低, 因此数据集中正例样本所占的比例相对于负例样本而言较低, 为了平衡正负样本不均衡导致模型训练效果不理想的情况, 本文的分类损失函数选择基于交叉熵损失函数改进的 Focal loss 函数, 表达式如式(16)所示, 可以解决由正负样本不均衡导致训练效果不佳的问题。

$$\text{Focal\_loss} = -\alpha(1-p_t)^\gamma \log(p_t) \quad (16)$$

$$p_t = \begin{cases} p, y=1 \\ 1-p, \text{otherwise} \end{cases}$$

$\alpha$  由正负样本比例确定, 关系如式(17),  $N_+, N_-$  分别为正例样本和负例样本的数量。

$$\frac{\alpha}{1-\alpha} = \frac{N_+}{N_-} \quad (17)$$

根据以上分析, 在实验中根据正负样本的大致

比例, 设置  $\alpha = 0.25, \gamma = 2$ 。因此, 分类损失函数表示为式(18)形式。

$$\text{Loss}_{\text{clf}} = -0.25(1-p_t)^2 \log(p_t) \quad (18)$$

图 6 中提到, 为了衡量提取的源域工程参数特征与目标域工程参数特征之间的差异性, 选用 CORAL 损失作为距离度量, 表达式如式(19)所示。

$$\text{Loss}_{\text{CORAL}} = \frac{1}{4d^2} \|\mathbf{C}_S - \mathbf{C}_T\|_F^2 \quad (19)$$

其中,  $\mathbf{C}_S, \mathbf{C}_T$  分别为源域和目标域卫星工程参数特征的协方差矩阵, 计算表达式为式(20)、(21),  $d$  为协方差矩阵维数。

$$\mathbf{C}_S = \frac{1}{N_S - 1} (\mathbf{z}_S' \mathbf{z}_S - \frac{1}{N_S} (\mathbf{1}' \mathbf{z}_S) (\mathbf{1}' \mathbf{z}_S)) \quad (20)$$

$$\mathbf{C}_T = \frac{1}{N_T - 1} (\mathbf{z}_T' \mathbf{z}_T - \frac{1}{N_T} (\mathbf{1}' \mathbf{z}_T) (\mathbf{1}' \mathbf{z}_T)) \quad (21)$$

其中,  $\mathbf{1}$  是元素值全为 1 的向量,  $\mathbf{z}_S'$  和  $\mathbf{z}_T'$  分别表示矩阵  $\mathbf{z}_S$  和  $\mathbf{z}_T$  的转置。

因此, 本文异常检测模型的优化目标为  $\min_{\theta} (\text{Loss}_{\text{clf}} + \text{Loss}_{\text{CORAL}})$ ,  $\theta$  为网络所需要优化的参数。

使用 SGD 更新网络参数, 学习率  $\eta$  设置为 0.005, 衰减方式为指数衰减。

综上所述, 基于 DRSN\_CORAL 的卫星工程参数异常检测模型构建流程如算法 1 所示。

**算法 1** 基于 DRSN\_CORAL 的卫星工程参数异常检测模型

**输入** 带标签的源域卫星工程参数  $\mathbf{D}_S = \{\mathbf{X}_S, \mathbf{Y}_S\}$ ,

无标签的目标域卫星工程参数  $\mathbf{D}_T = \{\mathbf{X}_T\}$ ,

学习率  $\eta$

**输出** 网络参数  $\theta$ , 目标域的预测类别标签

1. 初始化网络参数
2. while true:
3.   for  $x$  in  $\mathbf{D}_S, \mathbf{D}_T$ :
4.     根据  $\mathbf{z}_j = h(\mathbf{x}_j)$  计算特征表示;
5.     根据  $p = g(z_{j,S})$  计算分类输出;
6.     计算损失  $\text{Loss}_{\text{clf}} + \text{Loss}_{\text{CORAL}}$
7.     更新  $\theta$
8.   end for
9. end while

## 4 实验验证与分析

### 4.1 数据预处理

卫星工程参数中包含多种类型的变量,大致可以分为离散量和模拟量两大类。对于卫星工程参数中的离散量参数而言,需要将离散变量转为 One-Hot 编码。由于分类器往往默认数据是连续并且有序的,如果简单按照数字特征处理,那么分类器学习得到的是分段的值域划分规则,但参数离散量的取值并不是有序的,而是随机分配的。例如,在卫星工程参数数据有很多属性特征采用了多位数字编码,如“终端 A 机数据状态”有初态、发送、空闲、上行四种状态,原本使用 0、1、2、3 表示,使用 One-Hot 编码后表示为 1000、0100、0010、0001,每种状态扩充为四种特征来表示,有效解决了分类器对离散量划分的问题,在一定程度上也起到了扩充特征的作用,同时为后续实验中使用 Focal\_loss 损失函数奠定了计算基础。

除此之外,对于卫星工程参数中模拟量参数,需要对其进行数据归一化处理,将每个属性的特征值映射到(0,1)范围,以满足后续神经网络对输入数据的要求,归一化的数学表达式如式(22)所示。

$$x_{\text{scale}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (22)$$

其中,  $x_{\min}$ ,  $x_{\max}$  分别为该特征值的最小值和最大值,  $x$  为归一化之前的原始数据值,  $x_{\text{scale}}$  为归一化之后的参数特征值。

图 9 为量子卫星和“太极一号”的部分卫星工程参数经过数据归一化后随时间变化的趋势图。从图中可以看出,卫星工程参数大多呈周期性变化趋势,但是每个参数的周期存在差异,且数据中存在噪声干扰;少部分参数则呈现出无规则变化,直观上无法分析其数据特征。

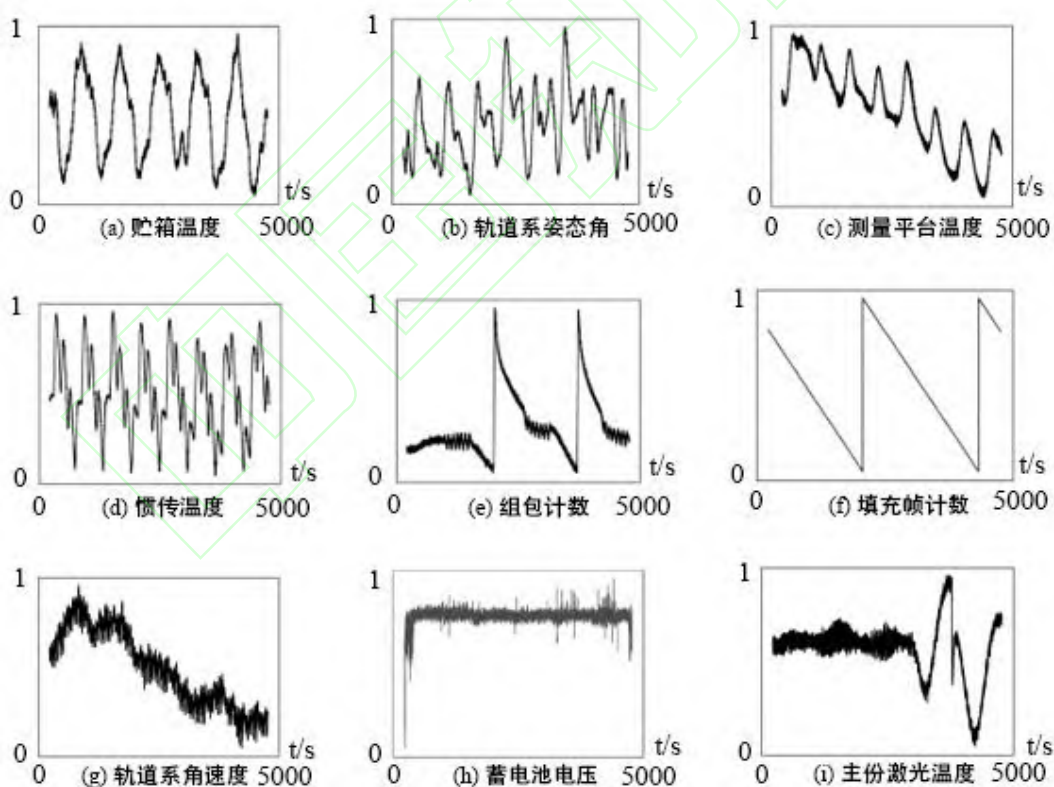


图 9 卫星部分参数变化趋势图

Fig.9 Trend of partial satellite engineering parameters

### 4.2 实验结果与分析

实验中所使用的编程语言为 Python,深度学习

框架为 Pytorch,实验过程中使用国家空间科学中心公共技术服务中心空间科学数据融合计算平台提供的计算服务,实验系统环境为 Linux Ubuntu18.04,

CPU 为 Intel i5 处理器@2.6GHz, GPU 为 NVIDIA Tesla K80。

利用量子卫星数据的三类数据样本 A1、A2、A3 分别作为源域数据和目标域数据,“太极一号”卫星三个子系统工程参数 B1、B2、B3 分别作为对应目标域数据和源域数据。而“A1→B1”表示以 A1 为源域、B1 为目标域的一组异常检测工作,“B1→A1”则表示以 B1 为源域、A1 为目标域的一组异常检测工作。其中,针对每一类异常检测任务,将目标域数据划分为训练集与测试集,比例为 7:3,训练集采用 K-折交叉验证方法,K 设置为 10。

卫星工程参数异常检测是一个二分类问题,在实验数据集准备中,将发生异常的卫星工程参数作为正例样本 (Positive),不存在异常的卫星工程参数作为负例样本 (Negative)。因此,有如下定义:

TP: 数据实际上为正例样本,预测结果也是正例样本的个数。

TN: 数据实际上为负例样本,预测结果也是负例样本的个数。

FP: 数据实际上为负例样本,预测结果是正例样本的个数。

FN: 数据实际上为正例样本,预测结果是负例样本的个数。

根据以上定义,本文中采用大多数卫星异常检测领域中所使用的通用评价指标:检测准确率,数学表达式如式(23)所示。

$$\text{accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \quad (23)$$

所选择的对比算法为梯度提升决策树 (Gradient Boosting Decision Tree, GBDT)<sup>[24]</sup>、支持向量机与 DRSN,其中,GBDT 与 SVM 是卫星工程参数异常检测领域表现优异的传统异常检测方法,DRSN 是不使用领域自适应迁移的网络模型,得到的实验结果如表 4 所示。

表 4 四种方法异常检测准确率结果对比

检测任务	GBDT	SVM	DRSN	本文方法
A1→B1	21.00%	18.34%	44.39%	<b>71.31%</b>
A2→B2	87.27%	61.13%	72.93%	<b>92.54%</b>
A3→B3	68.14%	87.17%	84.83%	<b>85.32%</b>
B1→A1	71.06%	72.35%	63.44%	<b>73.91%</b>
B2→A2	64.79%	<b>91.28%</b>	70.28%	89.73%
B3→A3	45.95%	45.52%	84.87%	<b>98.03%</b>
平均准确率	64.19%	62.63%	70.12%	<b>85.14%</b>

从表 4 可以看出,针对不同卫星相似分系统之间的跨平台异常检测任务,GBDT 和 SVM 方法的准确率波动较大,最低在 20%左右,甚至低于 20%,最高达到 90%以上,以 SVM 为例,模型异常检测表现最优时准确率相较于本文方法高出近 1.55 个百分点,这是由于 SVM 是线性分类器,对数据本身具有一定程度的线性依赖,数据的非线性较高,则 SVM 的分类效果不佳,平均准确率并不理想;此外,DRSN 的分类效果也并不理想,平均准确率较本文方法相差 15.02 个百分点,这是由于 DRSN 学习到的分类器只获取到了源域卫星工程参数的特征表示,无法获取源域与目标域之间共同的特征表示方法,因而,利用源域卫星工程参数的类别标签对目标域卫星;相对而言本文方法的异常检测效果则比较优异,在大多数的异常检测任务中均能够发挥出理想的效果,最高可达到 98.03%的检测准确率;在 B2→A2 的检测任务上,本文方法的准确率低于 SVM 方法 1.55 个百分点,总体上相差不大。除此之外,相较于 GBDT 和 SVM 方法,本文方法的平均准确率分别提高了 20.95 和 22.51 个百分点。所以,本文方法有效地完成了不同卫星相似分系统下的卫星工程参数异常检测的迁移任务。这也说明 DRSN 在增加了 CORAL 相似性度量的情况下,能够有效地将源域卫星工程参数数据和目标域卫星工程参数数据映射到一个相似空间,获取二者共同的特征表示,从而完成利用源域标签来对目标域卫星工程参数的分类任务。

在空间科学卫星任务中,异常检测是在每次数据传输接收数据之后进行的,也就是针对每一轨接收的数据进行一次检测,因此本文针对单轨接收的数据进行了检测性能比对,所得到的各算法对每一条数据平均运行时间结果对比如图 10 所示。

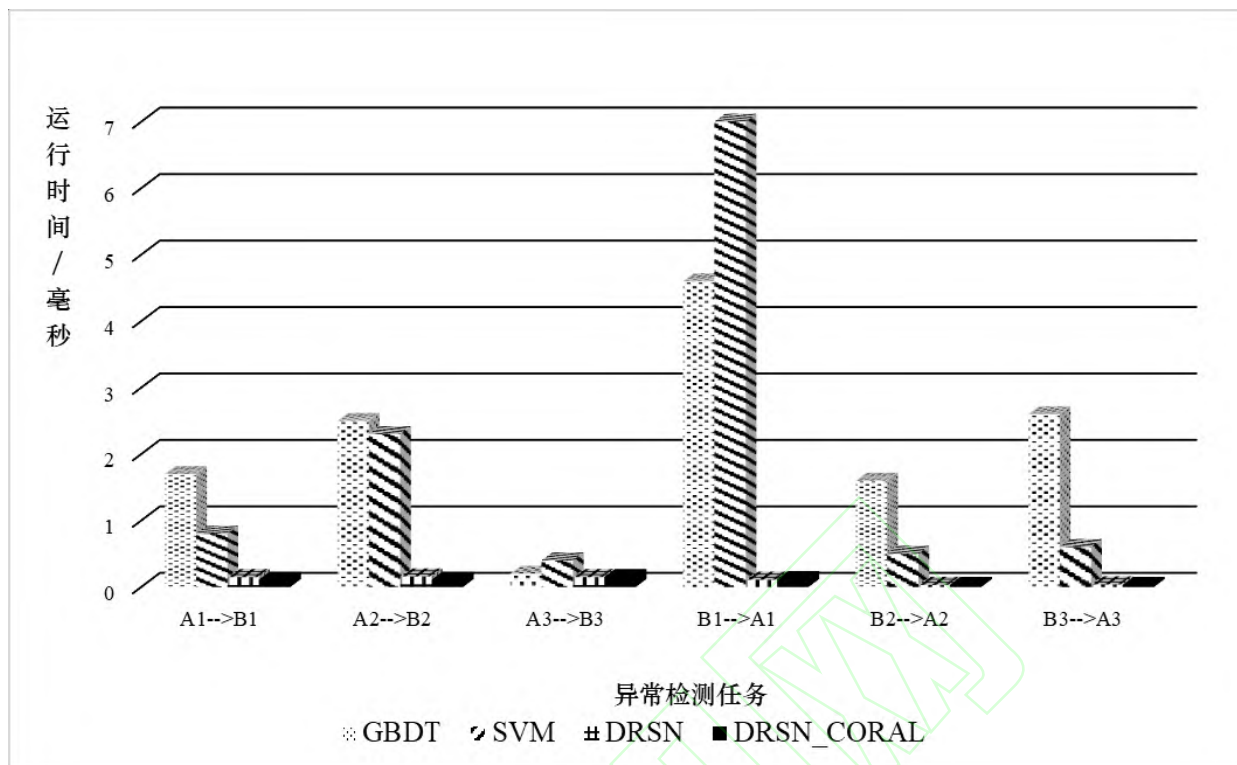


图 10 四种方法运行时间结果对比

Fig.10 Comparison of running time on four methods

在模型基于训练数据学习完成后,对新的单轨接收的样本完成异常检测任务时,本文方法所消耗的时间相较于 GBDT 和 SVM 有一定幅度的降低,可见,本文方法在检测速度上也得到相应提升,且能充分利用 GPU 的加速性能;而 DRSN 方法的运行速度与本文相差不大,这是训练好的 DRSN 网络与本文的网络整体结构上是一致的,网络每层的参数有所不同,因而模型在运行时间上并不会产生较大差别。相较于传统机器学习方法 GBDT 和 SVM,本文模型在训练好后,对测试集测试时运行速度的优势更加明显,基本可以实现对新下行的卫星工程参数实时检测的目标。

为了更加直观地体现特征提取效果,本文采用 t-SNE<sup>[25]</sup>数据降维方法,将提取到的源域特征和目标域特征映射到二维坐标系下,图 11-13 分别展示了源域为量子卫星工程参数、目标域为“太极一号”卫星工程参数的特征提取可视化结果,其中“anomaly”表示卫星工程参数异常数据特征,“normal”表示卫星工程参数正常数据特征。




图 11 A1→B1 检测任务特征提取效果

Fig.11 Visualization of feature extraction on task A1→B1






图 12 A2→B2 检测任务特征提取效果

Fig.12 Visualization of feature extraction on task A2→B2




图 13 A3→B3 检测任务特征提取效果

Fig.13 Visualization of feature extraction on task A3→B3

从图 11-13 中可以直观看出，本文 DRSN\_CORAL 模型实现了基于领域自适应的卫星异常检测目标，首先，网络有效地学习获取了源域和目标域卫星工程参数的特征表示  $h(\bullet)$ ，使得网络提取到的源域和目标域特征在特定映射空间上具有相似的数据分布；其次，模型通过利用源域卫星工程参数的类别标签，训练得到的分类函数  $g(\bullet)$ ，能够有效地将正常卫星工程参数与异常工程参数分离，说明本文方法能够利用已有卫星分系统的历史工程参数对未知的新卫星、新载荷的工程参数进行异常检测，从而实现不同卫星相似分系统之间的智能迁移检测任务。

## 5 结束语

卫星工程参数异常检测能够及时地判断卫星及星上载荷的健康状态，对卫星在轨高效安全运行至关重要。随着国家空间科学先导专项二期工程的推进，持续产生大量的工程参数，而目前应用于卫星工程参数异常检测领域的方法需要消耗人力和时间成本对体量庞大的数据进行精确的标注工作，且无法实现不同卫星相似分系统之间理想的异常检测效果。基于此，本文提出了基于领域自适应的卫星工程参数异常检测方法，通过将无标签的待检测数据引入模型的训练过程，挖掘源域卫星工程参数数据和目标域数据之间在特定子空间上的相似性，从而能够利用已有的卫星工程参数对不同卫星相似分系统下的数据进行异常检测。实验结果表明，本文方法在对新卫星上的工程参数异常检测准确率和效率方面均达到了预期效果，相较于传统的 GBDT 和 SVM 方法，体现出优异的异常检测性能；此外，相较于 DRSN 方法，在平均准确率上得到提升；最后，从降维至二维空间的可视化特征来看，模型不仅可以有效地学习到已有卫星和待检测卫星之间的联系，而且分类函数可以有效区分正例样本和负例样本，实现利用已有卫星工程参数在新卫星、新载荷工程参数上良好的迁移检测效果。

本方法可以利用预训练-微调的修正得到一个可泛化模型，有新的目标域卫星工程参数数据待检测时只需要对网络模型进行微调即可，无需再进行重复的网络训练工程，有效提高异常检测效率。然而本文对卫星工程参数的异常检测工作仅局限于判断数据是否发生异常的二分类问题，对于数据发生何种异常并无准确的结论，因此，在后续的研究中，可以考虑对卫星工程参数展开异常分类工作，即对异常数据发生的类别或者异常数据存在于哪一子系统下进行判定，获得更为精准的工程参数异常检测结果。

**致谢** 感谢国家科技资源共享服务平台-国家空间科学数据中心提供数据资源，感谢国家空间科学中心公共技术服务中心空间科学数据融合计算平台提供的计算服务。

## 参考文献

- [1] 王亚坤, 杨凯飞, 张捷, 等. 卫星在轨故障案例与人工智能故障诊断[J/OL]. 中国空间科学技术: 1-12[2021-10-19]. <http://kns.cnki.net/kcms/detail/11.1859.V.20210701.1702.002.html>.  
Wang Yakun, Yang Kaifei, Zhang Jie, et al. Case Study of In-orbit Satellite Failures and Artificial Intelligence Based Failure Detection[J/OL]. Chinese Space Science and Technology: 1-12[2021-10-19]. <http://kns.cnki.net/kcms/detail/11.1859.V.20210701.1702.002.html>.
- [2] 彭喜元, 庞景月, 彭宇, 等. 航天器遥测数据异常检测综述[J]. 仪器仪表学报, 2016, 37(09): 1929-1945.  
Peng Xiyuan, Pang Jingyue, Peng Yu, et al. Review on Anomaly Detection of Spacecraft Telemetry Data[J]. Chinese Journal of Scientific Instrument, 2016, 37(09): 1929-1945.
- [3] Decoste, Dennis. Automated Learning and Monitoring of Limit Functions[C]//International Symposium on Artificial Intelligence, Robotics, and Automation in Space, Tokyo, 1997.
- [4] Yairi T, Kawahara Y, Fujimaki R, et al. Telemetry-mining: a machine learning approach to anomaly detection and fault diagnosis for space systems[C]// IEEE International Conference on Space Mission Challenges for Information Technology. IEEE Computer Society, 2006.
- [5] Liu D, Pang J, Ge S, et al. Fragment Anomaly Detection with Prediction and Statistical Analysis for Satellite Telemetry[J]. IEEE Access, 2017, PP(99): 1-1.
- [6] 杨甲森. 卫星遥测数据相关性知识发现方法研究[D]. 中国科学院大学(中国科学院国家空间科学中心), 2019.  
Yang Jiasen. Research on Correlation Knowledge Discovery Method of Spacecraft Telemetry Data[D]. University of Chinese Academy of Sciences(National Space Science Center, UCAS), 2019.
- [7] Shawe-Taylor J, B Žlićar. Novelty Detection with One-Class Support Vector Machines[M]. Springer International Publishing, 2015.
- [8] Xu M. A Novel Framework for Anomaly Detection for Satellite Momentum Wheel Based on Optimized SVM and Huffman-Multi-Scale Entropy[J]. Entropy, 2021, 23.
- [9] 董静怡, 庞景月, 彭宇, 等. 集成 LSTM 的航天器遥测数据异常检测方法[J]. 仪器仪表学报, 2019, 40(07): 22-29.  
Dong Jingyi, Pang Jingyue, Peng Yu, et al. Spacecraft telemetry data anomaly detection method based on ensemble LSTM[J]. Chinese Journal of Scientific Instrument, 2019, 40(07): 22-29.
- [10] Wang Y, Wu Y, Yang Q, et al. Anomaly Detection of Spacecraft Telemetry Data Using Temporal Convolution Network[C]// 2021 IEEE International Instrumentation and Measurement Technology Conference (I2MTC). IEEE, 2021.
- [11] Junfu Chen, Dechang Pi, Zhiyuan Wu, et al. Imbalanced satellite telemetry data anomaly detection model based on Bayesian LSTM[J]. Acta Astronautica, 2021: 232-242.
- [12] 王婵, 王慧泉, 金仲和. 皮纳卫星遥测数据异常检测聚类分析方法[J]. 哈尔滨工业大学学报, 2018(4): 110-116.  
Wang Chan, Wang Huiquan, Jin Zhonghe. Pico-satellite Telemetry Anomaly Detection through Clustering[J]. Journal of Harbin Institute of Technology, 2018(4): 110-116.
- [13] Zhu Y, Xi D, Song B, et al. Modeling Users' Behavior Sequences with Hierarchical Explainable Network for Cross-domain Fraud Detection[J]. 2022.
- [14] Mallick T, Balaprakash P, Rask E, et al. Transfer Learning with Graph Neural Networks for Short-Term Highway Traffic Forecasting[C]//2020 25th International Conference on Pattern Recognition (ICPR), 2021.
- [15] Chen L. Deep Transfer Learning for Static Malware Classification[J]. 2018.
- [16] Oliveira J S, Souza G B, Rocha A R, et al. Cross-Domain Deep Face Matching for Real Banking Security Systems[J]. 2018.
- [17] Ahmed U, Khan A, Khan S H, et al. Transfer Learning and Meta Classification Based Deep Churn Prediction System for Telecom Industry[J]. 2019.
- [18] 刘飞, 陈仁文, 邢凯玲等. 基于迁移学习与深度残差网络的滚动轴承快速故障诊断算法[J]. 振动与冲击, 2022, 41(03): 154-164. DOI:10.13465/j.cnki.jvs.2022.03.019.  
Liu Fei, Chen Renwen, Xing Kailing, et al. Fast Fault Diagnosis Algorithm for Rolling Bearing Based on Transfer Learning and Deep Residual Network[J]. Journal of Vibration and Shock, 2022, 41(03): 154-164. DOI:10.13465/j.cnki.jvs.2022.03.019.
- [19] Li X, J Zheng, Li M, et al. Frequency-Domain Fusing Convolutional Neural Network: A Unified Architecture Improving Effect of Domain Adaptation for Fault

Diagnosis[J]. Sensors, 2021, 21(2):450.

- [20] 王晋东,陈益强.迁移学习导论[M]. 北京:电子工业出版社, 2021.

Wang Jindong, Chen Yiqiang. Introduction to Transfer Learning[M]. Beijing: Publishing House of Electronics Industry, 2021.

- [21] Sun B, Saenko K. Deep CORAL: Correlation Alignment for Deep Domain Adaptation[C]//Springer International Publishing. Springer International Publishing, 2016

- [22] Lecun Y. LeNet-5, convolutional neural networks[J].

- [23] Zhao M, Zhong S, Fu X, et al. Deep Residual Shrinkage Networks for Fault Diagnosis[J]. IEEE Transactions on Industrial Informatics, 2020, PP(99):1-1.

- [24] 马文臻, 王爱玲, 李旭东, 等.基于 GBDT 的卫星工程参数异常检测[J].计算机系统应用,2022,31(1):138-144.

Ma Wenzhen, Wang Ailing, Li Xudong, et al. Anomaly Detection of Satellite Engineering Data Based on GBDT[J]. Computer Systems and Applications, 2022,31(1):138-144.

- [25] Xudong L, Yang H, Jianhua Z, et al. Central Moment Discrepancy Based Domain Adaptation for Intelligent Bearing Fault Diagnosis[J]. Neurocomputing, 2020.